

PERK-ID: búsqueda visual de pastillas

Bioinformática y Medicina

Laura Cabaleiro, Marcelo Ferreiro, José Romero


Grado en Inteligencia Artificial

Problema que resuelve

Objetivo principal

Recuperar, a partir de una foto de entrada, las pastillas del dataset que más se parecen visualmente.

- Entrada: imagen desde cámara o galería.
- Salida: ranking Top-K con imagen, metadatos y sustancias asociadas.
- Enfoque: recuperación de imágenes por similitud.




Datos de partida

Imágenes y metadatos de pastillas obtenidos mediante extracción automatizada, procedentes de [Energy Control](#).


- Cada registro corresponde a una pastilla analizada.
- Se guardan imágenes cuando están disponibles.
- Los metadatos incluyen color, logo, procedencia, peso, diámetro y sustancias.
- La información queda estructurada en una tabla junto con las rutas de imagen.
- Antes de compararlas, las imágenes se normalizan: RGB, recorte centrado y tamaño fijo.



Ejemplos de transformaciones para simular capturas reales.



Arquitectura general




Normalización


Todas las imágenes se llevan al mismo formato antes de calcular los descriptores visuales.

- Conversión a RGB.
- Recorte centrado.
- Redimensionado a 256×256 .
- Salida homogénea para comparar imágenes.

Esto evita que el ranking dependa de diferencias de escala, formato o encuadre.



Descriptores visuales utilizados




Todos los descriptores se concatenan para representar cada pastilla mediante un vector comparable.

- **SIFT**: detecta puntos locales, logos, letras y bordes.
- **BoW**: convierte los descriptores SIFT en un vector fijo.
- **GLCM**: describe la textura global en escala de grises.
- **Hu Moments**: resume la forma global de la pastilla.
- **LBP**: captura microtexturas y patrones locales.

Cómo se construye el índice


- 1 Leer cada imagen del dataset.
- 2 Extraer GLCM, Hu Moments y LBP.
- 3 Extraer descriptores SIFT.
- 4 Entrenar KMeans para Bag of Words.
- 5 Concatenar todo en un vector final.
- 6 Guardar matriz de features e imágenes asociadas.



Funcionamiento

A partir de una imagen de consulta, el sistema extrae sus descriptores visuales y busca en el índice las pastillas más parecidas.

- Se calcula un vector de características para la imagen de entrada.
- Ese vector se compara con los vectores del índice visual.
- La búsqueda se realiza mediante vecinos más cercanos.
- Como resultado, se obtiene un ranking ordenado por similitud.




Interpretación

Cuanto menor es la distancia, mayor es la similitud visual con la imagen de entrada.

Funcionamiento

El backend actúa como intermediario entre la app y el sistema de búsqueda visual: recibe la imagen, consulta el ranking y construye la respuesta final.

- Recibe la imagen enviada desde la app mediante una petición POST /query.
- Carga el índice visual y los metadatos necesarios para resolver la consulta.
- Llama al módulo de ranking para obtener las pastillas más similares.
- Devuelve una respuesta estructurada con resultados, metadatos y sustancias asociadas.



Respuesta

La app recibe un JSON con las imágenes candidatas, sus distancias de similitud y los metadatos asociados.

Papel de la app

La app actúa como interfaz entre el usuario y el backend: captura la imagen, lanza la consulta y muestra los resultados.

- Permite usar la cámara o seleccionar una imagen de la galería.
- Envía la imagen al backend mediante una petición HTTP.
- Permite elegir cuántos resultados mostrar.
- Presenta el ranking de pastillas similares en tarjetas.

Tecnologías utilizadas

- **Flutter**: framework para construir la app móvil/web.
- **Dart**: lenguaje usado por Flutter.
- **camera**: acceso a la cámara del dispositivo.
- **image_picker**: selección de imágenes desde galería.
- **http**: envío de peticiones al backend.
- **shared_preferences**: guardado de configuración local.

Evaluación del índice

Objetivo

Evaluar si el índice recupera la pastilla original cuando la consulta es una versión transformada.

Proceso

- Se toman imágenes ya indexadas.
- Se generan consultas transformadas.
- Se compara cada consulta contra el índice.
- Se registra la posición de la imagen original.

Métricas: Top-1, Top-K, ranking medio, distancia media y tiempo de consulta.




Ejemplo visual: cada fila muestra una consulta transformada y los resultados recuperados por el índice.

Resultados

Métricas (100 consultas)

Top-1	0.68
Top-10	0.89
Rank medio	0.47
Fuera top-10	11/100
Tiempo medio	208 ms

Consultas generadas aplicando data augmentation: rotación, escala, ruido, blur y jitter simultáneos.




Cada fila: consulta transformada (izq.) y los primeros resultados del ranking. ★ marca la imagen original cuando aparece.

Autoencoder y Bounding Box: módulo experimental

Idea principal

Reconstruir imágenes de pastillas y predecir su localización mediante bounding boxes.

- El **encoder** comprime la imagen en una representación latente.
- El **decoder** reconstruye la imagen de entrada.
- Una cabeza adicional predice la caja: x, y, w, h .
- El modelo aprende a reconstruir la imagen y a localizar la pastilla a la vez.



Ejemplos de reconstrucción y predicción de bounding boxes.

Uso de una CNN

Como mejora futura, se podría sustituir o complementar el sistema actual de descriptores manuales por una red convolucional entrenada sobre las imágenes de pastillas.

- La CNN aprendería automáticamente patrones visuales relevantes como forma, color, textura, logos y marcas, sin definir cada descriptor a mano.

Ventajas esperadas

- Representaciones más adaptadas al dataset.
- Mayor robustez ante cambios de iluminación, escala o perspectiva.
- Es un sistema más escalable si aumenta el número de muestras.

La idea sería mantener el enfoque de recuperación visual, pero usando embeddings aprendidos por la CNN en lugar de depender solo de las features implementadas.

- Se ha construido un sistema de recuperación de pastillas basado en descriptores clásicos (SIFT + BoW) capaz de identificar la pastilla correcta en el top-10 en el **89 % de los casos** bajo condiciones mas o menos realistas de captura gracias al DA.
- El sistema sería implementable como app offline (integración nativa con Kotlin/Swift, sin necesidad de server FastAPI).
- El enfoque clásico se considera una ventaja en salud pública, ya que los modelos son interpretables y auditables, sin las limitaciones de explicabilidad del deep learning.

Muchas gracias por la atención